

一种基于元学习的空间目标 ISAR 图像超分辨算法

杨志雄, 夏靖远*, 周治兴, 廖淮璋, 张双辉, 付耀文, 黎湘

国防科学技术大学, 长沙, 中国

邮箱: (yzx21,j.xia10,zzx19,lhz17,zhangshuanghui,fuyaowen)@nudt.edu.cn
lixiang01@vip.sina.com

2023 年 4 月

摘要. 针对空间目标逆合成孔径雷达(Inverse Synthetic Aperture Radar, ISAR)图像的超分辨率问题, 本文提出了一种基于元学习的高效自适应ISAR图像超分辨算法。通常来说, 由于雷达成像系统的硬件限制, 空间目标的ISAR图像通常具有模糊、低分辨率等图像退化, 这些退化会导致后续目标检测识别等下行任务算法的性能下降。基于模型的传统方法往往在算法有效性上不如深度学习方法, 然而, 现有的基于深度学习的方法缺乏可解释性和泛化性能, 不能满足空间目标ISAR图像的超分辨任务的需求。针对上述问题, 本文提出了一种基于元学习的空间目标ISAR图像超分辨算法。该算法将ISAR图像退化模型中的先验信息和元学习求解策略进行结合, 通过引入ISAR图像退化先验并基于元学习优化策略进行求解, 实现了不依赖配对训练数据和预训练的空间目标ISAR图像超分辨。通过多组对比实验, 所提出的算法具有更好的超分辨性能和泛化性能。

关键词: 空间目标 逆合成孔径雷达, 图像超分辨, 元学习.

*通信作者: 夏靖远 j.xia10@nudt.edu.cn

A Meta-Learning Based Super-resolution Algorithm for Space Target ISAR Image

Yang Zhixiong, Xia Jingyuan*, Zhou Zhixing, Liao Huaizhang, Zhang Shuanghui, Fu Yaowen, Li Xiang

National University of Defense Technology, Changsha, China

E-mail: (yzx21,j.xia10,zzx19,lhz17,zhangshuanghui,fuyaowen)@nudt.edu.cn
lixiang01@vip.sina.com

April 2023

Abstract. This paper proposes a meta-learning-based and efficient blind super-resolution algorithm for space target ISAR image. Owing to the inherent hardware limitations of radar systems, inverse synthetic aperture radar (ISAR) images are often characterized by low resolution and blurring. As a result, downstream tasks such as target detection, recognition, and classification may become challenging. Traditional model-based approaches often lack effectiveness compared to deep learning-based methods. However, existing deep learning methods are lack of the interpretability and generalization performance, and are unable to meet the super resolution requirements on ISAR images of space targets. To address the aforementioned issues, we propose a meta-learning-based algorithm for ISAR images super-resolution of space targets. This algorithm integrates prior information on ISAR degradation model assumptions with meta-learning solution strategies, thereby introducing priors into the process of solving the ISAR image super-resolution problem via meta-learning. As a result, the proposed algorithm achieves ISAR images super-resolution without paired training data or pre-training. Comparative experiments demonstrate that the proposed algorithm has superior performance and generalization ability.

Keywords: Space target, Inverse Synthetic Aperture Radar, image super resolution, meta-learning.

*Corresponding Author: Xia Jingyuan j.xia10@nudt.edu.cn

1. 引言

由于环境和距离的影响,普通成像设备难以全天时、全天候获得远程高机动目标的高分辨率图像。因此,逆合成孔径雷达(Inverse Synthetic Aperture Radar, ISAR)逐渐成为获取轨道空间目标观测数据的主要工具。高分辨率ISAR图像对于雷达目标识别、分类和语义分割等后续任务至关重要。由于雷达系统往往受到成像设备的硬件限制,难以获得高分辨率的ISAR图像。因此,很多研究者致力于研究如何通过算法提高ISAR图像的分辨率,即ISAR超分辨算法研究。

现有的ISAR超分辨率算法主要分为基于模型的方法和基于深度学习的方法两大类。其中基于模型的方法通常根据空间目标ISAR图像特性(比如稀疏),手动设计ISAR图像先验。设计好的先验之后被运用于降低问题的非凸性质,从而提高ISAR图像的超分辨求解效率与性能。具体来说,方法[1-6]尝试通过设计稀疏模型来改进雷达成像过程,然而这些方法的性能高度依赖于雷达系统,因此稳定性和适应性有限;方法[7-11]聚焦于改进图像超分辨优化算法,基于高分辨率图像特点设计图像内在特征先验,并引入超分辨模型来获得更好的算法性能。总的来说,基于模型的方法通常具有明确数学模型,并在特定的超分辨率任务上表现良好。然而,现实中观测得到的ISAR图像往往质量较低,因此ISAR图像超分辨问题具有高度非凸性。此时手工设计的图像先验难以具备较好的泛化性能,不能有效地满足ISAR图像超分辨任务需求。

区别于基于模型的方法,基于深度学习的方法通过在大量标注数据集上进行训练,使得深度学习模型能够获得高分辨率图像的数据先验,从而实现对低分辨率图像的超分辨。比如方法[12-15]通过精心设计的端到端深度网络对ISAR图像进行超分辨求解,并基于大量的配对数据进行训练,均实现较好的ISAR图像超分辨性能。然而,对于空间目标ISAR图像来说,充足的高质量配对数据集往往难以构建,因此无法对端到端的深度神经网络进行有效训练,限制了这类方法在实际应用中的灵活性和可行性。因此,方法[16-18]尝试在没有训练数据的条件下,应用深度展开模型对图像超分辨问题进行求解。但由于问题本身高度病态非凸,这类方法所采用的交替优化策略容易使算法陷入局部最优解,导致超分辨效果不佳。

针对上述问题,本文提出了一种基于元学习的高效自适应ISAR图像超分辨算法。所提出方法通过在求解过程中引入基于学习驱动的ISAR图像退化模型先验,从而实现了在没有训练数据、没有预训练的情况下对超分辨问题准确稳定地求解。具体来说,本文提出一种基于元学习的ISAR图像超分辨算法框架,在该框架下,训练过程中的退化模型先验和元学习求解策略有机的结合在一起。其中元学习求解ISAR图像超分辨问题时实现了一种自适应优化策略。求解过程中引入的退化模型先验源于对随机模糊核的采样,实现了在没有配对训练数据情况下的先验信息引入,降低了问题求解的非凸性质和求解难度。最后,基于仿真的空间目标ISAR图像数据设计了多组对比实验,实验结果表明:本文方法可以在无监督条件下实现空间目标ISAR图像超分辨,并获得优于其他常规ISAR图像超分辨算法的性能。

2. ISAR 图像超分辨问题概述

本章首先介绍了 ISAR 图像退化模型，并以投影交替最小化方法（projected alternation minimization, PAM）[19]和双-图像深度先验方法（double deep image prior, Double-DIP）[20]框架为例，简要说明了 ISAR 图像超分辨问题中两个子问题的一般交替迭代求解策略。

2.1. ISAR 图像退化模型

根据现有方法对ISAR图像超分辨问题的定义，本文所考虑的ISAR图像退化模型如下所示：

$$\mathbf{Y} = \mathbf{A}\mathbf{X}\downarrow_s + \mathbf{N} \quad (1)$$

其中， $\mathbf{Y} \in \mathbb{C}^{M \times N}$ 表示低分辨率的ISAR图像， $\mathbf{X} \in \mathbb{C}^{sM \times sN}$ 表示高分辨率的ISAR图像， $\mathbf{A} \in \mathbb{C}^{M \times N}$ 表示ISAR图像的退化矩阵， \downarrow_s 表示高分辨率的ISAR图像的降采样， s 表示下采样倍数， $\mathbf{N} \in \mathbb{C}^{sM \times sN}$ 表示ISAR图像的加性噪声。 M 和 N 表示低分辨率ISAR图像的尺寸。

ISAR图像超分辨问题可以被建模为已知低分辨率ISAR图像的条件下求解高分辨率ISAR图像的问题。该问题的求解本身是一个病态非凸逆问题。通常求解该ISAR图像超分辨问题的目标函数表达式如下所示：

$$\arg \min_{\mathbf{X}} \{ \|\mathbf{Y} - \mathbf{A}\mathbf{X}\downarrow_s\|_F^2 + \alpha\varphi(\mathbf{X}) + \mu\omega(\mathbf{A}) \} \quad (2)$$

其中第一项为数据保真项，第二项和第三项分别为高分辨率ISAR图像的先验项和退化矩阵的先验项， α 和 μ 分别表示图像先验和退化矩阵先验的权重。

2.2. PAM 方法

在基于模型的方法中，最为典型的是投影交替最小化方法（projected alternation minimization, PAM）。该方法首先将问题（2）分解为对高分辨 ISAR 图像求解和对退化矩阵求解这两个子问题，如下所示：

$$\left\{ \arg \min_{\mathbf{X}} \{ \|\mathbf{Y} - \mathbf{A}\downarrow_s\|_F^2 + \alpha\varphi(\mathbf{X}) \} \right. \quad (3)$$

$$\left. \arg \min_{\mathbf{A}} \{ \|\mathbf{Y} - \mathbf{A}\downarrow_s\|_F^2 + \mu\omega(\mathbf{A}) \} \right\} \quad (4)$$

然后通过传统梯度求解算法，如梯度下降，交替迭代的对子问题（3）和（4）中的待求解变量进行交替迭代求解。更多的 PAM 方法细节可以参考[19]。

2.3. Double-DIP 方法

在基于学习的方法中，最为典型的是双-图像深度先验方法（double-deep image prior, Double-DIP）。该方法同样是将问题（2）分解为对高分辨 ISAR 图像求解和对退化矩阵求解这两个子问题。但是与 PAM 方法不同的是，Double-DIP 方法利用两个深度神经网络来分别求解高分辨 ISAR 图像和退化矩阵，如下所示：

$$\begin{cases} X = G_X(\mathbf{z}_X, \boldsymbol{\theta}_X), \mathbf{A} = G_A(\mathbf{z}_A, \boldsymbol{\theta}_A) & (5) \\ \arg \min_{\boldsymbol{\theta}_X} \{\|\mathbf{Y} - \mathbf{A}G_X(\mathbf{z}_X, \boldsymbol{\theta}_X)\|_F^2 + \alpha\varphi(G_X(\mathbf{z}_X, \boldsymbol{\theta}_X))\} & (6) \\ \arg \min_{\boldsymbol{\theta}_A} \{\|\mathbf{Y} - G_A(\mathbf{z}_A, \boldsymbol{\theta}_A)\mathbf{X}\|_F^2 + \mu\omega(G_A(\mathbf{z}_A, \boldsymbol{\theta}_A))\} & (7) \end{cases}$$

然后通过现有的网络参数优化器，如 Adam[21]，交替迭代地对子问题（6）和（7）中的网络参数进行求解。更多的 Double-DIP 方法细节可以参考[20]。

3. 方法介绍

本文所提出的空间目标 ISAR 图像超分辨率方法总共包含退化先验引入模块和元学习优化模块两部分。本章将首先分别介绍退化先验引入过程和元学习优化过程，然后介绍所提出方法的整体实现。本文所提方法基于 Double-DIP 的基础框架进行实现，同样采样两个深度学习网络分别生成高分辨率 ISAR 图像和退化矩阵。

3.1. 退化先验引入

在每一次退化先验引入迭代过程中，用于生成退化模型矩阵的网络的参数将被引入的退化先验更新，使得网络能够生成更准确的退化矩阵。考虑到传统基于模型的方法设计的固定先验信息不能满足复杂多变的空间目标 ISAR 图像超分辨率任务需求。首先构建一个包含有 R 个潜在的退化矩阵的退化矩阵库 \mathcal{D}_A ，如下所示：

$$\mathcal{D}_A = \{\mathbf{A}^r\}_{r=1}^R \quad (8)$$

然后每一次迭代过程中，从退化矩阵库中随机抽取一个或一组退化矩阵，作为当前迭代过程中退化先验，用于更新网络参数。

在第 t 次迭代过程开始，退化矩阵生成网络首先基于当前的网络参数和一个随机初始化但是固定的噪声输入，生成当前预测的退化矩阵，如下所示：

$$\mathbf{A}^i = G_A(\mathbf{z}_A, \boldsymbol{\theta}_A^i) \quad (9)$$

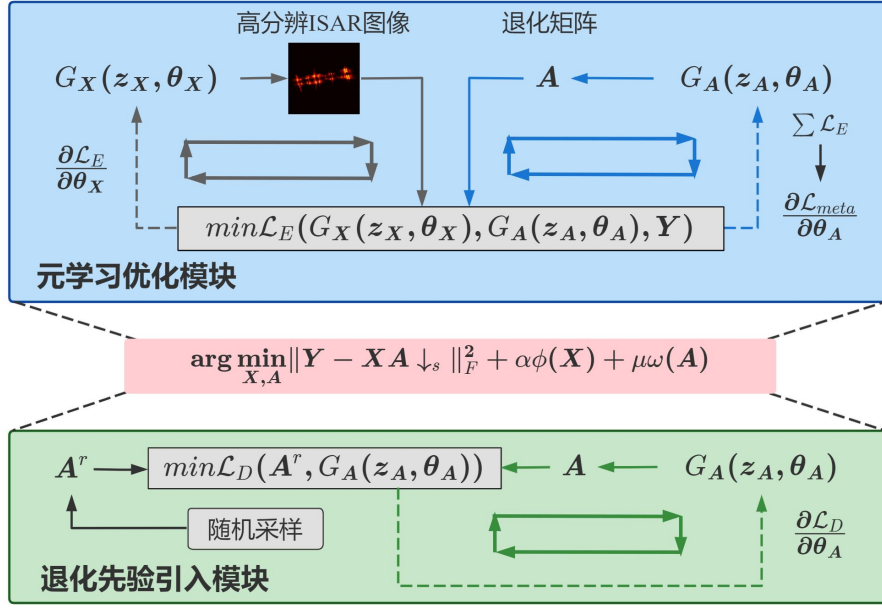
其中， \mathbf{z}_A 表示一个预生成好的固定的高斯噪声作为网络 $G_A(\cdot)$ 的输入， $\boldsymbol{\theta}_A^i$ 表示第 i 次迭代过程中的网络参数。令第 i 次迭代过程随机抽取到的一组退化矩阵为 $\{\mathbf{A}^{i,r}\}_{r=r_1}^{r_2}$ ，并计算随机抽取得到的退化矩阵与网络所生成当前预测的退化矩阵的差异作为损失。值得注意的是，这里不是每一个随机抽样到的退化矩阵计算的损失都直接用于更新网络参数，而是计算这一组退化矩阵的累积差异损失，如下所示：

$$\mathcal{L}_D^i = \frac{1}{(r_2 - r_1 + 1)} \sum_{r=r_1}^{r_2} \omega^r \|\mathbf{A}^{i,r} - G_A(\mathbf{z}_A, \boldsymbol{\theta}_A^i)\|_F^2 \quad (10)$$

其中 \mathcal{L}_D^i 为第 i 次迭代过程的累积差异损失， ω^r 为权重。然后退化矩阵生成网络的网络参数利用 Adam 优化器进行优化，如下所示：

$$\boldsymbol{\theta}_A^{i+1} = \boldsymbol{\theta}_A^i - \gamma_A^i \cdot \text{Adam}(\nabla_{\boldsymbol{\theta}_A} \mathcal{L}_D^i) \quad (11)$$

图 1 本文方法示意图



值得注意的是，每一次迭代过程中采样数可以根据任务需求设置，也可以在一次迭代过程中只采样一个退化矩阵。

3.2. 元学习优化

在第 i 次元学习优化迭代过程开始，两个深度神经网络分别基于各自的网络参数和随机初始化但是固定的噪声输入来生成一个高分辨 ISAR 图像和一个对退化矩阵，如下所示：

$$\begin{cases} X^{i,t} = G_X(z_X, \theta_X^{i,t}) \\ A^i = G_A(z_A, \theta_A^i) \end{cases} \quad (12)$$

$$\quad (13)$$

其中， z_X 表示一个预生成好的固定的高斯噪声作为网络 $G_X(\cdot)$ 的输入， $\theta_X^{i,t}$ 表示迭代过程中的网络参数。网络所生成的退化矩阵和高分辨率 ISAR 图像计算重构误差作为损失，如下所示：

$$\mathcal{L}_E^{i,t} = \|Y - A^i X^{i,t}\|_F^2 + \alpha \phi(X^{i,t}) \quad (14)$$

其中 $\mathcal{L}_E^{i,t}$ 为迭代过程的图像重构误差损失。高分辨率 ISAR 图像生成网络的网络参数利用 Adam 优化器进行优化，如下所示：

$$\theta_X^{i,t+1} = \theta_X^{i,t} - \gamma_X^{i,t} \cdot \text{Adam}(\nabla_{\theta_X} \mathcal{L}_E^{i,t}) \quad (15)$$

值得注意的是，本文方法不用图像重构误差损失贪婪地每一次都更新退化矩阵生成网络的网络参数。而是引入一种元学习的参数优化策略，通过累积多次图像重构误差损失来计算元学习损失，如下所示：

$$\mathcal{L}_{meta}^i = \frac{1}{(t_2 - t_1 + 1)} \sum_{t=t_1}^{t_2} \omega^t \|Y - A^i X^{i,t}\|_F^2 \quad (16)$$

其中 \mathcal{L}_{meta}^i 为第*i*次迭代过程的元学习损失， ω^t 为权重。退化矩阵生成网络的网络参数利用 Adam 优化器进行优化，如下所示：

$$\theta_A^{i+1} = \theta_A^i - \gamma_{A,meta} \cdot Adam(\nabla_{\theta_A} \mathcal{L}_{meta}^i) \quad (17)$$

在这种情况下，网络参数不再最小化每个单独的图像重建误差，而是通过最小化累积的元学习损失来优化网络参数，因此实现了一种不贪婪且更自适应的优化策略。更多的元学习优化方法细节可以参考[22-23]。

算法 1: 一种基于元学习的ISAR图像超分辨算法

```

1  给定：低分辨率ISAR图像 $Y$ 。
2  初始化：网络参数 $\theta_A^0, \theta_X^{0,0}$ ，网络输入 $z_A, z_X$ 。
3  for  $i \leftarrow 0, 1, \dots, I$  do
4       $\{A^{i,r}\}_{r=r_1}^{r_2} \leftarrow$  随机采样
5       $\mathcal{L}_D^i = \frac{1}{(r_2-r_1+1)} \sum_{r=r_1}^{r_2} \omega^r \|A^{i,r} - G_A(z_A, \theta_A^i)\|_F^2$ 
6      for  $t \leftarrow 0, 1, \dots, T$  do
7           $X^{i,t} = G_X(z_X, \theta_X^{i,t}), A^i = G_A(z_A, \theta_A^i)$ 
8           $\mathcal{L}_E^{i,t} = \|Y - A^i X^{i,t} \downarrow_s\|_F^2 + \alpha \varphi(X^{i,t})$ 
9           $\theta_X^{i,t+1} = \theta_X^{i,t} - \gamma_X^{i,t} \cdot Adam(\nabla_{\theta_X} \mathcal{L}_E^{i,t})$ 
10     end
11      $\theta_X^{i+1,0} \leftarrow \theta_X^{i,T}$ 
12      $\mathcal{L}_{meta}^i = \frac{1}{(t_2-t_1+1)} \sum_{t=t_1}^{t_2} \omega^t \|Y - A^i X^{i,t} \downarrow_s\|_F^2$ 
13      $\theta_A^{i+1} = \theta_A^i - \gamma_A^i \cdot Adam(\nabla_{\theta_A} (\mathcal{L}_D^i + \mathcal{L}_{meta}^i))$ 
14 end
15 输出： $X^{I,0}$ .
```

3.3. 整体实现

本文方法实现流程如**算法 1**所示，本文方法示意图如图1所示。在每一次迭代开始，先从构建好的退化矩阵库中随机抽取一组退化矩阵 $\{A^{i,r}\}_{r=r_1}^{r_2}$ ，作为该次迭代过程的先验信息。通过公式（10）计算退化矩阵累积差异损失 \mathcal{L}_D^i 。值得注意的是，在最终的算法实现中，本文方法不通过公式（11）直接更新网络参数，而是与后面计算的元学习损失两项合并一起更新网络参数。本文方法通过公式（14）计算T次图像重构误差损失，并通过公式（15）直接更新高分辨率ISAR生成网络的参数。在T次更新之后，再通过公式（16）计算这T次迭代累积的元学习损失 \mathcal{L}_{meta}^i 。最后将计算的退化矩阵累积差异损失 \mathcal{L}_D^i 和累积的元学习损失 \mathcal{L}_{meta}^i 合并在一起，通过合并公式（11）与公式（17），从而实现对退化矩阵网络参数的自适应更新。

综上所述，本文方法实现了在没有数据训练，也没有训练过程的条件下，对低分辨率ISAR图像进行实时、自适应的超分辨率求解。在更新迭代过程中通过公式（10）-（11）引入随机抽样得到的先验弥补了现有方法中先验信息单一且固定的问题。而

元学习的优化迭代策略则通过公式（16）-（17）计算迭代过程中累积的元学习损失，并与退化矩阵累积差异损失相结合来更新网络参数，实现了一种自适应、非贪婪的优化策略，从而保证了算法对空间目标ISAR图像超分辨问题的高效、准确求解。

4. 实验结果与分析

4.1. 实验设置

本文所用测试数据集是一个公开的空间目标 ISAR 图像数据集，共有 3000 张空间目标 ISAR 图像，其中包含三个不同角度的三种不同空间目标。其中每张高分辨率的空间目标 ISAR 图像的大小为 240×240 ，下采样倍数 s 设置为 2。低分辨率 ISAR 图像由公式（1）得到，退化矩阵设置为任意的高斯模糊核，公式（1）中的矩阵相乘运算在这里设置为卷积运算。在测试阶段，本文方法不使用任何训练数据，也没有任何的预训练过程，也不知道退化矩阵和高分辨率空间目标 ISAR 图像的真值信息。考虑到空间目标 ISAR 图像通常是灰度图像，图像的可视化效果较差。为了达到增强 ISAR 图像可视化效果的目的，本文方法通过伪彩色渲染增强灰度 ISAR 图像，以获得更好的可视化效果。在对比实验中，本文方法将对比两种基于模型的图像超分辨方法：bicubic 和 PAM，以及两种基于学习的图像超分辨方法：DIP 和 Double-DIP。

4.2. 实验结果及分析

表 1 给出了在缩放倍数为 2 的情况下，对于三种不同目标数据集，所有 ISAR 图像超分辨方法得到的高分辨率 ISAR 图像的 PSNR 值和 SSIM 值。在表中能够发现本文方法在所有条件下都实现了最好的 ISAR 图像超分辨性能。尤其是在目标 2 数据集上，本文方法在 PSNR 指标上高出性能第二名算法 2.64dB。图 2 展示了所有方法超分辨的可视化结果对比。本文方法的超分辨结果在定量评价结果和定性的视觉效果上都是最优的。

表 1 所有方法在空间目标 ISAR 图像数据集上的平均性能对比

目标编号	1		2		3	
方法	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
bicubic	28.61	0.9015	31.07	0.9415	30.86	0.9300
PAM	23.72	0.8975	24.65	0.9063	24.74	0.9074
DIP	29.30	0.9093	31.98	0.9482	31.45	0.9359
Double-DIP	28.02	0.9007	30.82	0.9451	31.89	0.9427
本文方法	30.32	0.9238	33.46	0.9610	32.70	0.9478

4.3. 消融实验

表 2 对本文方法中引入的两个步骤：退化先验引入和元学习优化，分别进行消融实验。在表中能够发现本文方法在所有条件下都实现了最好的 ISAR 图像超分辨性能。在没有退化先验引入步骤时，本文方法在求解过程中缺失先验信息，导致了 1dB 以上的大

幅度性能下降,而在没有元学习优化步骤时,本文方法在求解过程中容易陷入局部最优,导致了不到 1dB 的小幅度性能下降。

图 2 所有方法在三种空间目标 ISAR 图像上的可视化对比




表 2 本文方法的消融实验

方法		定量评价					
目标编号		1		2		3	
退化先验引入	元学习优化	PSNR	SSIM	PSNR	SSIM	PSNR	SSIM
×	×	28.02	0.9007	30.82	0.9451	31.89	0.9407
×	√	28.40	0.9057	31.31	0.9493	32.01	0.9425
√	×	29.97	0.9195	32.50	0.9547	32.49	0.9451
√	√	30.32	0.9238	33.46	0.9610	32.70	0.9478

5. 结论

本文提出了一种基于元学习的高效、自适应 ISAR 图像超分辨算法。本文方法在含有 3 种不同空间目标的 ISAR 图像数据集上进行了广泛的对比实验。实验结果证明了本文方法的有效性和优越性。尤其是在 ISAR 图像的退化矩阵未知的情况下,本文方法通过在求解过程中引入退化先验,解决了现有算法在空间目标 ISAR 图像求解过程中,先验信息不足的问题;通过引入元学习优化,实现了一种自适应、非贪婪的优化策略,有效地防止了算法在求解时陷入局部最优。与现有 ISAR 图像超分辨算法相比,本文方法实现了最优的超分辨性能。

6. 参考文献

- [1] L. Zhang, Z.-J. Qiao, M.-D. Xing, J.-L. Sheng, R. Guo, and Z. Bao, "High-resolution isar imaging by exploiting sparse apertures," *IEEE Transactions on Antennas and Propagation*, vol. 60, no. 2, pp. 997–1008, 2011.
- [2] S. Peng, S. Li, X. Xue, X. Xiao, D. Wu, X. Zheng, and B. Zhou, "High-resolution w-band isar imaging system utilizing a logic-operation-based photonic digital-to-analog converter," *Optics express*, vol. 26, no. 2, pp. 1978–1987, 2018.
- [3] C. A-lei, D.-W. Wang, X.-Y. Ma, and Y. Su, "Method of super resolution imaging for isar based on estimation theory," *Systems Engineering and Electronics*, p. 04, 2010.
- [4] L. Zhang, H. Wang, and Z.-j. Qiao, "Resolution enhancement for isar imaging via improved statistical compressive sensing," *EURASIP Journal on Advances in Signal Processing*, vol. 2016, no. 1, pp. 1–19, 2016.
- [5] G. Xu, M.-D. Xing, X.-G. Xia, Q.-Q. Chen, L. Zhang, and Z. Bao, "High-resolution inverse synthetic aperture radar imaging and scaling with sparse aperture," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 8, no. 8, pp. 4010–4027, 2015.
- [6] S.-J. Wei, X.-L. Zhang, J. Shi, and G. Xiang, "Sparse reconstruction for sar imaging based on compressed sensing," *Progress in electromagnetics research*, vol. 109, pp. 63–81, 2010.
- [7] D. Glasner, S. Bagon, and M. Irani, "Super-resolution from a single image," in *2009 IEEE 12th international conference on computer vision*. IEEE, 2009, pp. 349–356.
- [8] J. Yang, J. Wright, T. S. Huang, and Y. Ma, "Image super-resolution via sparse representation," *IEEE transactions on image processing*, vol. 19, no. 11, pp. 2861–2873, 2010.
- [9] D. Yang and J. Sun, "Proximal dehaze-net: A prior learning-based deep network for single image dehazing," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 702–717.
- [10] Li, R., Zhang, S., Zhang, C., Liu, Y. and Li, X., 2020. Deep learning approach for sparse aperture ISAR imaging and autofocus based on complex-valued ADMM-Net. *IEEE Sensors Journal*, 21(3), pp.3437-3451.
- [11] Li, R., Zhang, S., Zhang, C., Liu, Y. and Li, X., 2021. A computational efficient 2-D block-sparse ISAR imaging method based on PCSBL-GAMP-Net. *IEEE*

- [12] Qin, Dan, and Xunzhang Gao. "Enhancing ISAR resolution by a generative adversarial network." *IEEE Geoscience and Remote Sensing Letters* 18.1 (2020): 127-131.
- [13] Yang, Ting, et al. "ISAR imaging enhancement: Exploiting deep convolutional neural network for signal reconstruction." *International Journal of Remote Sensing* 41.24 (2020): 9447-9468.
- [14] Qin, Dan, et al. "ISAR resolution enhancement using residual network." 2019 IEEE 4th International Conference on Signal and Image Processing (ICSIP). IEEE, 2019.
- [15] Wang, Haobo, et al. "ISAR Resolution Enhancement Method Exploiting Generative Adversarial Network." *Remote Sensing* 14.5 (2022): 1291.
- [16] Ulyanov, Dmitry, Andrea Vedaldi, and Victor Lempitsky. "Deep image prior." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018.
- [17] Liang, Jingyun, et al. "Flow-based kernel prior with application to blind super-resolution." *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2021.
- [18] Yue, Zongsheng, et al. "Blind Image Super-resolution with Elaborate Degradation Modeling on Noise and Kernel." *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022.
- [19] D. Perrone and P. Favaro, "A clearer picture of total variation blind deconvolution," *IEEE transactions on pattern analysis and machine intelligence*, vol. 38, no. 6, pp. 1041–1055, 2015.
- [20] D. Ren, K. Zhang, Q. Wang, Q. Hu, and W. Zuo, "Neural blind deconvolution using deep priors," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020, pp. 3341–3350.
- [21] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.
- [22] Xia, Jing-Yuan, et al. "Metalearning-Based Alternating Minimization Algorithm for Nonconvex Optimization." *IEEE Transactions on Neural Networks and Learning Systems* (2022).
- [23] Yang, Zhixiong, et al. "A Learning-Aided Flexible Gradient Descent Approach to MISO Beamforming." *IEEE Wireless Communications Letters* 11.9 (2022): 1895-1899.