

# 基于物理先验的空间目标光学-ISAR 图像跨域生成

廖淮璋， 夏靖远， 杨志雄， 刘振， 刘永祥

国防科技大学电子科学学院，长沙，中国

邮箱: (lhz17, j.xia10, yzx21, zhen\_liu)@nudt.edu.cn, lyx\_bible@sina.com

2022 年 4 月

**摘要.** 生成对抗网络 (Generative Adversarial Networks, GANs) 在图像翻译任务中取得了巨大的成功，但其在跨域图像翻译任务中的应用仍有待探索。本文重点研究存在较大物理特性差异的不同图像跨域转换方法，特别是光学图像域与逆合成孔径雷达 (Inverse Synthetic Aperture Radar, ISAR) 图像域之间的图像转换。高质量的 ISAR 图像数据对空间目标的监视、识别、和情报获取都发挥着重要作用。在实际应用中，空天目标的 ISAR 图像数据的收集难度大、图像样本数量少，然而现有的深度学习方法需要依托大量高质量数据进行模型训练从而被应用于 ISAR 图像处理领域。因此，从光学图像域到 ISAR 图像域的图像转换生成具有重要的现实意义。本文首次研究了通过图像翻译技术从空间目标（如飞机、卫星）的光学图像生成对应 ISAR 图像。为了实现该目标，本文提出了一种基于物理先验的循环生成对抗网络 (Physical Domain Prior CycleGAN, PDP-CycleGAN) 以学习 ISAR 图像中的物理域特征。具体而言，本文通过构建基于特征隐空间的拉格朗日函数损失函数，使得生成模型能够在训练中学习 ISAR 图像的散射点分布特征。本文采用尺度不变特征变换 (Scale Invariant Feature Transform, SIFT) 算法提取 ISAR 图像中的散射点强度、分布与散射点强度变化方向，并基于此构建 ISAR 图像域的物理先验一致性。通过一致性的构建，PDP-CycleGAN 能够学习 ISAR 图像域与光学图像域的可逆映射，从而获取生成空间目标的 ISAR 图像的生成器。基于合成的 ISAR-光学空间目标数据的大量实验验证了 PDP-CycleGAN 算法的有效性，证明了 PDP-CycleGAN 算法在多目标 ISAR 图像生成方面具有良好的可行性与通用性。

**关键词:** 图像生成; 逆合成孔径雷达 (ISAR) 图像生成; 循环对抗生成网络

# Physical Domain Prior CycleGAN: Image Generation from the Optical to the ISAR Domain for Space Targets

Liao Huaizhang, Xia Jingyuan, Yang Zhixiong Liu Zhen and Liu Yongxiang

National University of Defense Technology, Changsha, China

E-mail: (lhaz17, j.xia10, yzx21, zhen\_liu)@nudt.edu.cn, lyx\_bible@sina.com

April 2022

**Abstract.** Despite of great success of Generative Adversarial Networks (GANs) in various image translation tasks, the application of GANs on cross-domain translation task is still under-explored. This paper focuses on image translation between domains with great physical differences, particularly, the Inverse Synthetic Aperture Radar (ISAR) and optical domains. High quality ISAR image plays a significant role in the areas of space target recognition, monitoring, and intelligence. However, the data collection of the ISAR images in practice is not always feasible and the number of the ISAR samples is typically insufficient, especially for the space targets. Meanwhile, the state-of-the-art deep learning techniques rely on abundant high quality training data to be applied to ISAR image processing society. Therefore, image translation from the optical to the ISAR domain is of great practical significance. For the first time, this paper studies the problem of generating ISAR images from their optical counterparts for space targets, such as aircraft and satellites. To achieve this goal, a physical domain prior CycleGAN (PDP-CycleGAN) is proposed to learn the domain-specific physical feature of ISAR images. Specifically, a lagrange loss is designed to favour learning the scattering feature of ISAR images via constituting a latent feature space. A Scale Invariant Feature Transform (SIFT) is applied to capture the scattering intensity, distribution, and direction of the intensity variation of scattering points is adopted to formulate a physical consistency in ISAR domain. In this way, the PDP-CycleGAN forms an invertible mapping between the ISAR and optical domains, thereof allowing the generator to leverage the translation to fabricate the ISAR image of space targets with respect to the optical resources. Extensive experiments on synthetic ISAR-optical space targets datasets have validated the effectiveness of the proposed PDP-CycleGAN and show that PDP-CycleGAN achieved good feasibility and generalization on ISAR image generation of multiple space targets.

**Keywords:** Image Translation; Inverse Synthetic Aperture Radar Image Generation; CycleGAN

## 1. 引言

随着深度学习的发展，生成对抗网络（Generative Adversarial Networks, GANs）<sup>[1][2]</sup>在图像生成领域中取得了巨大成功，基于GAN的图像翻译方法<sup>[3-9]</sup>在光学图像翻译方面取得了丰硕的成果，产生了诸如图像合成<sup>[10]</sup>、图像转换<sup>[11][12]</sup>等新兴应用。然而，针对物理特征差异较大的不同图像域的图像翻译技术的研究方兴未艾，目前没有一个通用模型能解决显著物理特性差异条件下的跨域图像转换生成问题。

逆合成孔径雷达（Inverse Synthetic Aperture Radar, ISAR）能够全天时、全天候对空天目标进行监测，因此其在模式识别、雷达信号处理与国家安全领域中占据着重要地位。然而，空间目标（如飞机和卫星）的ISAR图像，在实际中往往不易获取且成本高昂，严重阻碍了基于数据驱动的深度学习类检测识别算法的应用。相反，空间目标的光学图像则存在大量公开的数据。因此，本文旨在解决光学图像域到ISAR图像域的图像转换生成问题，为基于深度学习的空天目标检测识别算法的应用提供数据支撑。

ISAR图像本质上反映了空天目标在雷达波下的物理特征，包括散射点强度、分布与强度变化方向等特征。而现有的光学图像翻译方法难以兼顾以上物理特征，因此对ISAR图像生成的效果较差；同时，基于深度学习的识别检测模型通常依赖于大量的训练样本以得到优秀的性能保证。然而在实际应用中，空间目标的ISAR图像数量很少，因此限制了现有的前沿深度学习方法在ISAR图像处理中的应用。

针对上述问题，本文提出了一种基于物理先验的循环生成对抗网络（Physical Domain Prior CycleGAN, PDP-CycleGAN），以解决光学图像域到ISAR图像域的图像转换问题。本文构建了基于尺度不变特征变换（Scale Invariant Feature Transform, SIFT）算法的ISAR散射点物理先验一致性框架，用于构建特征隐空间。PDP-CycleGAN由两个循环组成：前向循环旨在实现“ISAR-光学-ISAR”图像域的转换，而后向循环则构成“光学-ISAR-光学”图像域的转换。这使得PDP-CycleGAN中的生成器能够学习ISAR图像域中的物理特征与光学图像域中的结构特征，从而生成高质量的图像。为了降低模型的训练数据需求，本文将物理先验一致性的等式约束形式转化为增广拉格朗日损失函数，增强PDP-CycleGAN的泛化能力，使得其对陌生目标具有良好的生成能力。在不同类型的飞机与卫星的未配对数据集上的大量实验表明，所提出的PDP-CycleGAN成功从光学目标图像生成了具有真实物理特征的ISAR图像。

本文的贡献具体体现在以下三个方面：

（1）本文提出了PDP-CycleGAN模型，用于解决存在显著差异物理特征的不同图像域的图像翻译问题。PDP-CycleGAN在特征隐空间中构建了物理先验一致性，使得生成模型能够学习ISAR图像中的散射点物理特征信息，实现了ISAR图像高质量生成。

（2）本文基于增广拉格朗日函数，构造了基于物理先验一致性的损失函数。该损失函数使得模型具有良好的数理可解释性，降低了模型对训练数据的依赖，提高了对陌生目标ISAR图像生成的能力。

（3）与传统图像翻译方法相比，PDP-CycleGAN在学习ISAR图像的物理特征方面具有更高的效率。在飞机与卫星目标的数据集上进行的实验表明，提出的PDP-CycleGAN在所有场景中均取得了优异的性能。

## 2. 相关工作

### 2.1. 基于GAN的图像翻译

基于GAN的模型是解决图像翻译任务的主要方法之一。其中，使用最广泛的模型包括条件GAN（conditional GAN，cGAN）<sup>[13]</sup>，CycleGAN<sup>[6]</sup>与StarGAN<sup>[8]</sup>。具体而言，基于cGAN的Pix2Pix模型<sup>[7]</sup>通过加入1范数损失，使得生成器保持输入图像与输出图像的低频特征。该方法在配对图像转换、图像修复<sup>[14]</sup>、风格迁移<sup>[15]</sup>等任务中取得了良好的性能。基于Pix2Pix的框架，CycleGAN同时训练两个GAN模型，并利用图像域的循环一致性，学习原图像域与目标图像域的可逆转换。该方法成功实现了无监督条件下的图像翻译，并在物体转换<sup>[16]</sup>和图像增强<sup>[17]</sup>等任务中得到了充分的应用。具体而言，CycleGAN的对抗损失函数可表示为：

$$\mathcal{L}_{\text{GAN}}(G_{IO}, D_O, \mathbf{I}, \mathbf{O}) = \mathbb{E}_O[\log D_O(\mathbf{O})] + \mathbb{E}_I[\log(1 - D_O(G_{IO}(\mathbf{I})))] \quad (1)$$

其中 $\mathbf{I}$ 和 $\mathbf{O}$ 分别代表ISAR图像域和光学图像域的输入图像。定义 $G_{IO}$ 和 $G_{OI}$ 为CycleGAN中的两个生成器，分别表示ISAR到光学图像域的转换与光学到ISAR图像域的转换。定义 $D_I$ 和 $D_O$ 为CycleGAN的两个判别器，分别用于区分ISAR图像域与光学图像域中的真实样本与生成样本。

CycleGAN通过基于图像整体的循环一致性实现原图像域与目标图像域的双向翻译。对于来自ISAR图像域的每个输入图像 $\mathbf{I}$ ，循环一致性表现为： $\mathbf{I} \rightarrow G_{IO}(\mathbf{I}) \rightarrow G_{OI}(G_{IO}(\mathbf{I})) \approx \mathbf{I}$ <sup>[6]</sup>。具体而言，循环一致性损失数学形式为：

$$\mathcal{L}_{\text{cyc}}(G_{IO}, G_{OI}, \mathbf{I}, \mathbf{O}) = \mathbb{E}_I[\|G_{OI}(G_{IO}(\mathbf{I})) - \mathbf{I}\|_1] + \mathbb{E}_O[\|G_{IO}(G_{OI}(\mathbf{O})) - \mathbf{O}\|_1] \quad (2)$$

然后，根据公式（1）和（2），CycleGAN的总损失函数可以表达为：

$$\mathcal{L}_{\text{CycleGAN}} = \mathcal{L}_{\text{GAN}}(G_{IO}, D_O, \mathbf{I}, \mathbf{O}) + \mathcal{L}_{\text{GAN}}(G_{OI}, D_I, \mathbf{O}, \mathbf{I}) + \lambda_{\text{cyc}} \mathcal{L}_{\text{cyc}}(G_{IO}, G_{OI}, \mathbf{I}, \mathbf{O}) \quad (3)$$

其中， $\lambda_{\text{cyc}}$ 表示循环一致性损失的权重参数。除了基于GAN的方法，UNIT<sup>[18]</sup>提出了一种基于变分自编码的框架，在非配对图像翻译任务中也取得了良好的性能。受前述研究的启发，本文提出了一种基于散射点物理特征的物理先验一致性，使得生成的ISAR图像与原始ISAR图像在隐空间中保持的散射点物理特征的一致。

### 2.2. 雷达图像处理与特征提取

图像翻译方法在SAR与ISAR中的应用主要包括SAR图像到光学图像的转换<sup>[19][20]</sup>与ISAR图像姿态补全生成<sup>[21]</sup>。[20]提出了一种基于结构相似性指数（Structural Similarity，SSIM）特征的生成对抗模型，用于学习SAR图像到光学图像的映射。该工作实现了在配对训练数据集中的SAR图像到光学图像的转换，但由于缺乏SAR图像的散射点物理先验信息，模型难以生成农田、森林等土地覆盖和纹理信息的特征。[21]提出了一种基于对抗自编码器框架的ISAR样本生成模型，用于飞机ISAR图像的多方位角下的插值生成。但是，该工作仅利用了图像层面的结构重构损失的一致性，忽略了ISAR图像固有的物理特征，如散射点强度、分布等。因此，本文基于SIFT算法，将原始ISAR图像映射到特征隐空间中以实现ISAR图像散射点物理特征的提取。在SIFT算法中，采用差分高斯（DoG）映射函数，以滤除ISAR图像中的低频信息。DoG尺度空间包含ISAR图像的关键特征，DoG映射函数通常定义为：

$$S(x, y, \sigma) = (N(x, y, k\sigma) - N(x, y, \sigma)) \otimes I(x, y) \quad (4)$$

其中 $\otimes$ 表示卷积操作， $k$ 是描述不同图像尺度的比例系数， $I(x, y)$ 表示带有散射点坐标 $(x, y)$ 的输

入ISAR图像,  $N(x, y, \sigma) = \frac{1}{2\pi\sigma^2} \exp\{-\frac{x^2+y^2}{2\sigma^2}\}$  是带有图像尺度系数 $\sigma$ 的分布。该映射旨在DoG尺度空间中查找具有大强度的关键散射点。关键散射点的精确坐标计算方式为:

$$\hat{c} = c_0 - \frac{\partial^2 S^{-1}}{\partial c^2} \frac{\partial S}{\partial c}, \quad (5)$$

其中,  $c_0 = (x_0, y_0, \sigma_0)$  表示在DoG尺度空间中经过与周围空间的26个点比较后, 具有最大强度的散射点,  $\hat{c}$  是反映ISAR图像在DoG尺度空间中分布与强度的关键散射点的精确坐标。进一步, 利用 $\hat{c}$ 的坐标寻找在DoG尺度空间中散射点强度变化方向及其对应模长, 分别用 $\theta(x, y)$ 与 $\mathcal{M}(x, y)$ 表示, 分别表示为:

$$\theta(x, y) = \arctan \frac{(\mathcal{L}(x, y+1) - \mathcal{L}(x, y-1))}{(\mathcal{L}(x+1, y) - \mathcal{L}(x-1, y))}, \quad (6)$$

$$\mathcal{M}(x, y) = \sqrt{(\mathcal{L}(x+1, y) - \mathcal{L}(x-1, y))^2 + (\mathcal{L}(x, y+1) - \mathcal{L}(x, y-1))^2}, \quad (7)$$

其中 $\mathcal{L}(x, y) = N(x, y, \sigma) \otimes I(x, y)$ 。本文基于SIFT算法, 将ISAR散射点物理特征与循环一致性相结合, 以实现生成模型对ISAR散射点物理特征的学习。

### 3. 基于物理先验的循环生成对抗网络

本文提出了一种基于物理先验的循环生成对抗网络 (PDP-CycleGAN), 用于实现光学图像域到ISAR图像域的转换生成。具体而言, 我们利用SIFT算法对ISAR散射点物理特征先验实进行提取, 构建循环一致性, 并将CycleGAN模型的总优化目标重新设计为基于增广拉格朗日函数的数学形式, 以增强模型的数理可解释性。

#### 3.1. ISAR 图像的物理先验

现有的光学图像域到ISAR图像域的图像翻译方法在ISAR图像域散射点物理特征的提取方面存在明显缺陷, 导致其图像生成性能受到限制。本文基于SIFT算法对ISAR图像中的散射点特征进行提取, 从而能够显式地对ISAR图像进行物理特征建模。根据公式 (5)、(6) 和 (7), ISAR图像的散射点特征提取过程可表示为:

$$\{\mathbf{v}_k\}_{k=1}^K = P_S(\mathbf{I}), \quad (8)$$

其中 $\mathbf{v}_k = [\hat{c}_k, \theta_k, \mathcal{M}_k]^T, (k = 1, 2, \dots, K)$  是从原始ISAR图像中提取的第 $k$ 个散射点的特征向量,  $P_S(\cdot)$  表示SIFT提取过程。类似地, 生成的ISAR图像 $\mathbf{I}'$ 的特征向量可定义为:

$$\{\mathbf{v}'_k\}_{k=1}^K = P_S(\mathbf{I}'), \quad (9)$$

其中 $\mathbf{v}'_k = [\hat{c}'_k, \theta'_k, \mathcal{M}'_k]^T, (k = 1, 2, \dots, K)$ 。

#### 3.2. 循环一致性

本文将传统CycleGAN中的循环一致性分为两部分: “光学-ISAR-光学”转换流程中的像素一致性与“ISAR-光学-ISAR”转换流程中的物理先验一致性。其中, 像素一致性的表达式如下所示:

$$\mathcal{L}_{\text{pix}} = \|G_{IO}(G_{OI}(\mathbf{O})) - \mathbf{O}\|_2^2, \quad (10)$$

其中 $G_{IO}(G_{OI}(\mathbf{O}))$  表示模型重构的光学图像,  $\mathbf{O}$  表示输入的光学图像。该公式表明, 重构得到的光学图像 $G_{IO}(G_{OI}(\mathbf{O}))$  应当与输入的真实光学图像 $\mathbf{O}$  目标结构特征方面保持一致。与像一致性不同, 物理先验一致性则表示经过SIFT提取后的输入ISAR图像与重构的ISAR图像之间的散射点特征应当保持一致, 其损失函数表达式如下所示:

$$\mathcal{L}_{\text{ISAR}} = \left\| P_S(G_{OI}(G_{IO}(\mathbf{I}))) - P_S(\mathbf{I}) \right\|_2^2, \quad (11)$$

其中 $G_{OI}(G_{IO}(\mathbf{I}))$ 表示重构的ISAR图像， $\mathbf{I}$ 表示输入的ISAR图像。令 $\mathcal{L}_{G1} = \mathcal{L}_{\text{GAN}}(G_{IO}, D_O, \mathbf{I}, \mathbf{O})$ 和 $\mathcal{L}_{G2} = \mathcal{L}_{\text{GAN}}(G_{OI}, D_I, \mathbf{O}, \mathbf{I})$ 。基于公式（3）、（8）和（9），所提出的PDP-CycleGAN的总优化目标可表示为

$$\arg \min_{G_{IO}, G_{OI}} \max_{D_I, D_O} \mathcal{L}_{G1} + \mathcal{L}_{G2} + \lambda_{\text{pix}} \mathcal{L}_{\text{pix}} + \lambda_{\text{ISAR}} \mathcal{L}_{\text{ISAR}}, \quad (12)$$

其中 $\lambda_{\text{pix}}$ 与 $\lambda_{\text{ISAR}}$ 为权重参数。

### 3.3. 基于增广拉格朗日乘子的PDP-CycleGAN

为提高模型的数理可解释性与泛化能力，公式（12）中的ISAR物理先验一致性损失可重新构建为优化问题中的等式约束。具体而言，整个问题可以重新表示为：

$$\begin{aligned} \arg \min_{G_{IO}, G_{OI}} \max_{D_I, D_O} \mathcal{L}_{G1} + \mathcal{L}_{G2} + \lambda_{\text{pix}} \mathcal{L}_{\text{pix}} \\ \text{s.t. } \mathbf{v}_k = \mathbf{v}'_k, k = 1, 2, \dots, K. \end{aligned} \quad (13)$$

基于增广拉格朗日函数，上述数学形式可设计为：

$$\mathcal{L}_{\text{PDP}} = \mathcal{L}_{G1} + \mathcal{L}_{G2} + \lambda_{\text{pix}} \mathcal{L}_{\text{pix}} + \sum_{k=1}^K \lambda_k (\mathbf{v}_k - \mathbf{v}'_k) + \frac{\rho}{2} \|\mathbf{v}_k - \mathbf{v}'_k\|_2^2, \quad (14)$$

其中 $\lambda_k$ 是拉格朗日乘子， $\rho$ 表示罚函数系数。增广拉格朗日乘子通过 $\mathcal{L}_{\text{PDP}}$ 的梯度反传进行更新，其更新表达式为：

$$\lambda_k^{i+1} = \lambda_k^i - \beta \nabla_{\lambda_k^i} \mathcal{L}_{\text{PDP}}, \quad (15)$$

其中 $\beta$ 表示乘子的学习率， $i$ 是网络训练时的迭代索引。

PDP-CycleGAN的整体算法如算法1所示。假设训练的总次数为 $N$ 。在每次训练中，交替更新生成器和判别器；同时进行ISAR-光学与光学-ISAR的两种图像翻译。在每次迭代中，根据方程（14）计算 $\mathcal{L}_{\text{PDP}}$ 以更新生成器 $G_{IO}$ 和 $G_{OI}$ 的参数 $\phi_{G_{IO}}$ 与 $\phi_{G_{OI}}$ 。对于判别器 $D_I$ 和 $D_O$ ，分别基于相应的损失函数 $\mathcal{L}_{D_I}$ 和 $\mathcal{L}_{D_O}$ 更新参数 $\phi_{D_I}$ 与 $\phi_{D_O}$ 。

---

#### 算法1: PDP-CycleGAN算法

---

输入： (1) ISAR训练样本 $\mathbf{I}, \{\mathbf{I}_i, i = 1, \dots, m\}$ ；光学训练样本 $\mathbf{O}, \{\mathbf{O}_i, i = 1, \dots, m\}$ ； (2) 参数：权重参数 $\rho$ ，学习率 $\alpha$ 与 $\beta$ ；

输出：训练完成的生成器 $G_{IO}$ 和 $G_{OI}$ ；判别器 $D_I$ 和 $D_O$ 。

- 1:     初始化生成器 $G_{IO}$ 和 $G_{OI}$ ；判别器 $D_I$ 和 $D_O$ ；
- 2:     **while** epoch  $\leftarrow 1, 2, \dots, N$  **do**
- 3:         **while**  $i \leftarrow 1, 2, \dots, m$  **do**
- 4:              $\mathbf{I}'_i = G_{OI}(G_{IO}(\mathbf{I}_i))$ ;
- 5:              $\mathbf{O}'_i = G_{IO}(G_{OI}(\mathbf{O}_i))$ ;
- 6:              $\mathcal{L}_{\text{pix}} = \|\mathbf{O}'_i - \mathbf{O}_i\|_2^2$ ;
- 7:              $\mathbf{v}_k (k = 1, 2, \dots, K) \leftarrow P_S(\mathbf{I}_i)$ ;
- 8:              $\mathbf{v}'_k (k = 1, 2, \dots, K) \leftarrow P_S(\mathbf{I}'_i)$ ;
- 9:              $\mathcal{L}_{\text{prc}} = \sum_{k=1}^K \lambda_k (\mathbf{v}_k - \mathbf{v}'_k) + \frac{\rho}{2} \|\mathbf{v}_k - \mathbf{v}'_k\|_2^2$ ;

```

10:  $\mathcal{L}_{\text{PDP}} = \mathcal{L}_{\text{G1}} + \mathcal{L}_{\text{G2}} + \lambda_{\text{pix}} \mathcal{L}_{\text{pix}}$ 
11:  $\phi_{G_{IO}}^{i+1} = \phi_{G_{IO}}^i - \alpha \cdot \text{Adam}(\nabla_{\phi_{G_{IO}}^i} \mathcal{L}_{\text{PDP}});$ 
12:  $\phi_{G_{OI}}^{i+1} = \phi_{G_{OI}}^i - \alpha \cdot \text{Adam}(\nabla_{\phi_{G_{OI}}^i} \mathcal{L}_{\text{PDP}});$ 
13:  $\mathcal{L}_{D_I} = (D_I(I_i) - 1)^2 + D_I(G_{OI}(\mathbf{O}_i))^2;$ 
14:  $\mathcal{L}_{D_O} = (D_O(\mathbf{O}_i) - 1)^2 + D_O(G_{IO}(I_i))^2;$ 
15:  $\phi_{D_I}^{i+1} = \phi_{D_I}^i - \alpha \cdot \text{Adam}(\nabla_{\phi_{D_I}^i} \mathcal{L}_{D_I});$ 
16:  $\phi_{D_O}^{i+1} = \phi_{D_O}^i - \alpha \cdot \text{Adam}(\nabla_{\phi_{D_O}^i} \mathcal{L}_{D_O});$ 
17:  $\lambda_k^{i+1} = \lambda_k^i - \beta \nabla_{\lambda_k^i} \mathcal{L}_{\text{PDP}};$ 
18: end while
19: end while

```

图1 展示了PDP-CycleGAN的总体架构。其中， $G_{IO}$ 和 $G_{OI}$ 分别表示从ISAR到光学图像域与从光学到ISAR图像域的映射。该框架由两个循环组成：前向循环表示“ISAR-光学-ISAR”的转换；后向循环则表示“光学-ISAR-光学”的转换。图中右侧的蓝线表示“光学-ISAR-光学”的图像转换流程，而左侧红线则表示“ISAR-光学-ISAR”的图像转换流程。在该框架中，PDP-CycleGAN通过像素一致性和物理先验一致性，实现两种循环的整合。这两种循环一致性建立了一个基于散射点物理特征与光学结构特征的可逆映射，从而实现了有效的图像生成。

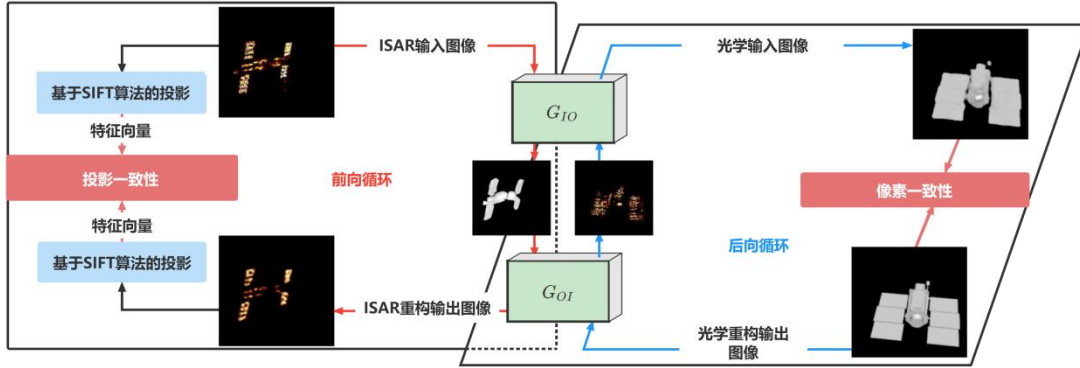


图1 PDP-CycleGAN总体框架图

#### 4. 实验与仿真结果

本节中，我们将对PDP-CycleGAN进行ISAR图像生成测试。为对比PDP-CycleGAN方法对于ISAR图像生成的性能，我们将本文所提方法与传统主流方法CycleGAN、UNIT进行对比，并通过初始分数（Inception Score，IS）<sup>[22-24]</sup>与多尺度结构相似度指数（Multi-scale Structural

Similarity, MS-SSIM) [25]对生成的ISAR图像进行定量评估。




图2 卫星与飞机数据集样本样例图

本文中的所有实验均采用飞机与卫星目标的非配对数据集。其中飞机目标数据集中的光学图像由收集而来，ISAR图像则是通过仿真平台仿真收集得到；卫星目标数据集中的光学由公共互联网与CAD仿真平台收集得到，ISAR图像则通过FEKO平台仿真合成。我们在图2中展示了两种数据集的部分样例。下面将给出PDP-CycleGAN模型的训练参数：模型最大迭代次数设置为100次；Adam<sup>[26]</sup>优化器的学习率 $\alpha$ 设置为 $8 \times 10^{-4}$ ；拉格朗日乘子的学习率 $\beta$ 设置为 $2 \times 10^{-4}$ ；像素一致性的权重 $\lambda_{\text{pix}}$ 设置为5；罚函数系数 $\rho$ 设置为10。

#### 4.1. 非配对图像翻译结果

本文首先在飞机与卫星非配对数据集上进行了ISAR图像的转换生成。图3和图4分别展示了不同方法在飞机与卫星空间数据集上得到的ISAR图像转换结果。在图3和图4中，每一行表示每一种图像翻译方法生成的ISAR图像，第一行表示输入的光学图像。




图3 非配对飞机目标ISAR图像翻译结果

显然，在空天目标的ISAR图像转换生成任务中，PDP-CycleGAN获得了比其他方法更好的生成结果。具体而言，在图3中，CycleGAN、UNIT方法生成的ISAR图像未有的散射点特征，并有明显的结构部件缺失。相反，PDP-CycleGAN生成的ISAR图像则体现了明显的散射点分布与强度特征，同时转换得到的飞机目标主体结构完整。在图4中，PDP-CycleGAN仍然



取得了最佳结果，其在散射点分布、强度等特征上与真实的ISAR图像保持一致，而其他两种方法仅提取了卫星的轮廓特征，主体结构有较大缺失。




图4 非配对卫星目标ISAR图像翻译结果图

#### 4.2. 方位角变换下空间目标翻译结果

空间目标的ISAR散射点分布、强度等特征与雷达观测角、目标方位角有关。本实验进一步评估了三种方法在目标方位角变换时对ISAR图像的生成性能，得到的翻译结果如图5所示。当光学目标方位角变换时，PDP-CycleGAN生成的ISAR图像在散射点分布、强度方面有着明显变化，这与真实散射点分布、强度变化情况相同。然而，UNIT和CycleGAN仅生成了具有ISAR散射点风格的伪图像。




图5 卫星目标方位角变换下ISAR图像翻译结果图

#### 4.3. 陌生目标 ISAR 图像翻译结果

在本实验中，我们进一步测试了PDP-CycleGAN对陌生卫星目标的生成能力。PDP-CycleGAN、CycleGAN与UNIT首先在仅包含单一卫星目标的数据集中进行训练，然后对陌生目标进行转换生成测试。图8展示了三种方法所生成的陌生卫星目标ISAR图像。陌生目标的ISAR图像生成的结果表明：与真实ISAR图像相比，PDP-CycleGAN生成的ISAR失真最小，而CycleGAN和UNIT表现出明显的结构部件缺失。表1分别计算了三种方法的对应的IS和MS-SSIM指标，定量评估生成的ISAR图像分布与真实ISAR图像分布之间的相似度。数据评估结果如表1所示。评估表明，PDP-CycleGAN具有最佳的性能，我们认为这源于PDP-CycleGAN实现了基于增广拉格朗日乘子的物理先验一致性损失，提高了所提模型的数理可解释性和泛化能力。




图8 陌生卫星目标翻译结果对比图

表1 陌生目标ISAR图像翻译结果

评估指标	IS	MS-SSIM
CycleGAN	1.06	0.2306
UNIT	1.08	0.2519
<b>PDP-CycleGAN</b>	<b>1.27</b>	<b>0.2940</b>

## 5. 结论

本文提出了一种基于物理先验的循环对抗生成模型。该模型通过将原有的循环一致性损失替换为像素一致性与物理先验一致性，实现模型对ISAR散射点的物理特征学习。模型的总体转换流程可分为两部分：“ISAR-光学-ISAR”和“光学-ISAR-光学”转换。我们利用SIFT算法获取原始和生成的ISAR图像中关键散射点的特征向量，并构建物理先验一致性。在非配对的空间目标数据集上进行的大量实验表明，本文所提出的方法能够生成高质量的ISAR图像。在未来，基于ISAR的成像原理，本文将进一步利用ISAR散射特征进行物理特征的一致性建模。此外，从ISAR域进行高质量的光学图像复原也具有重要的实际和理论意义。

## 6. 参考文献

- [1] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
- [2] Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]//International conference on machine learning. PMLR, 2017: 214-223.
- [3] Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.
- [4] Isola P, Zhu J Y, Zhou T, et al. Image-to-image translation with conditional adversarial networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1125-1134.
- [5] Choi Y, Choi M, Kim M, et al. Stargan: Unified generative adversarial networks for multi-domain image-to-image translation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8789-8797.
- [6] Huang X, Liu M Y, Belongie S, et al. Multimodal unsupervised image-to-image translation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 172-189.
- [7] Lee H Y, Tseng H Y, Huang J B, et al. Diverse image-to-image translation via disentangled representations[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 35-51.
- [8] Richardson E, Alaluf Y, Patashnik O, et al. Encoding in style: a stylegan encoder for image-to-image translation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 2287-2296.
- [9] Zhan F, Yu Y, Cui K, et al. Unbalanced feature transport for exemplar-based image translation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 15028-15038.
- [10] Shamsolmoali P, Zareapoor M, Granger E, et al. Image synthesis with adversarial networks: A comprehensive survey and case studies[J]. Information Fusion, 2021, 72: 126-146.
- [11] Yin Z, Xia K, He Z, et al. Unpaired image denoising via Wasserstein GAN in low-dose CT image with multi-perceptual loss and fidelity loss[J]. Symmetry, 2021, 13(1): 126.
- [12] Jiang M, Zhi M, Wei L, et al. FA-GAN: Fused attentive generative adversarial networks for MRI image super-resolution[J]. Computerized Medical Imaging and Graphics, 2021, 92: 101969.
- [13] Mirza M, Osindero S. Conditional generative adversarial nets[J]. arXiv preprint arXiv:1411.1784, 2014.
- [14] Liu H, Wan Z, Huang W, et al. Pd-gan: Probabilistic diverse gan for image inpainting[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 9371-9381.
- [15] Xu W, Long C, Wang R, et al. Drb-gan: A dynamic resblock generative adversarial network for artistic style transfer[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 6383-6392.
- [16] Luo Z, Zhang Y, Zhong P, et al. DiGAN: Directional Generative Adversarial Network for Object Transfiguration[C]//Proceedings of the 2022 International Conference on Multimedia Retrieval. 2022: 471-479.
- [17] Upadhyay U, Sudarshan V P, Awate S P. Uncertainty-aware GAN with adaptive loss for robust MRI image enhancement[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 3255-3264.
- [18] Liu M Y, Breuel T, Kautz J. Unsupervised image-to-image translation networks[J]. Advances in neural information processing systems, 2017, 30.

- [19] Sun Y, Jiang W, Yang J, et al. SAR target recognition using cGAN-based SAR-to-optical image translation[J]. Remote Sensing, 2022, 14(8): 1793.
- [20] Hwang J, Yu C, Shin Y. SAR-to-optical image translation using SSIM and perceptual loss based cycle-consistent GAN[C]//2020 International Conference on Information and Communication Technology Convergence (ICTC). IEEE, 2020: 191-194.
- [21] Zhou R Y, Yang Z L, Wang F. ISAR Images Generation Via Generative Adversarial Networks[C]//2021 IEEE International Geoscience and Remote Sensing Symposium IGARSS. IEEE, 2021: 5267-5270.
- [22] Salimans T, Goodfellow I, Zaremba W, et al. Improved techniques for training gans[J]. Advances in neural information processing systems, 2016, 29.
- [23] Barratt S, Sharma R. A note on the inception score[J]. arXiv preprint arXiv:1801.01973, 2018.
- [24] Chong M J, Forsyth D. Effectively unbiased fid and inception score and where to find them[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 6070-6079.
- [25] Wang Z, Simoncelli E P, Bovik A C. Multiscale structural similarity for image quality assessment[C]//The Thrity-Seventh Asilomar Conference on Signals, Systems & Computers, 2003. Ieee, 2003, 2: 1398-1402.
- [26] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," arXiv preprint arXiv:1412.6980, 2014.
- [27] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [28] Chen G, Zhang G, Yang Z, et al. Multi-scale patch-GAN with edge detection for image inpainting[J]. Applied Intelligence, 2022: 1-16.